

# 数值分析期末实践报告

郭宇祺

## 1 出勤说明

本人全勤。

## 2 LAPACK 分析

### 2.1 线性方程组求解函数分析

对于线性方程组  $Ax = b$ , LAPACK 使用 LU 分解（等价于高斯消元法）进行求解，涉及的函数包括以下几种，其中 `xx` 用于指定输入矩阵的类型，包括稠密矩阵（`ge`），带状阵（`gb`）和三对角阵（`gt`）：

- `_xxtrf`: 使用普通的 LU 分解求解线性方程组。稠密矩阵版本（`_getrf`）和带状阵版本（`_gbtrf`）采用了矩阵分块的性能优化手段，三对角阵版本（`_gttrf`）没有采用特殊的性能优化手段。
- `_xxtrs`: 使用普通的 LU 分解求解线性方程组。使用 `_xxtrf` 作为底层实现，但是与 `_xxtrf` 不同之处在于，该函数要求系数矩阵  $A$  是一个方阵，而 `_xxtrf` 没有此要求。与 `_xxtrf` 类似，稠密矩阵版本（`_getrs`）和带状阵版本（`_gbtrs`）采用了矩阵分块的性能优化手段，三对角阵版本（`_gttrs`）没有采用特殊的性能优化手段。
- `_xxrfs`: 此算法执行优化迭代，修正解以减少误差并估计（解的）误差的界。三个版本的函数都没有采用特殊的性能优化手段。

### 2.2 对称特征值问题求解函数分析

假设  $A$  是待求特征值的实对称矩阵（厄米特矩阵同理，此处略去），在 LAPACK 中，首先通过函数 `_sytrd`（稠密存储矩阵）、`_spttrd`（块状存储矩阵）或 `_sbtrd`（带状存储矩阵）将矩阵  $A$  归约为实三对角阵  $T$ ，即做分解  $A = QTQ^T$ 。随后对  $T$  求解特征值问题，即求  $T = SAS^T$ ，则  $\Lambda$  的对角元就是  $A$  的特征值，且  $Z = QS$  的列向量就是对应的特征向量。函数 `_orgtr` 用来显式地计算  $Q$ 。这个函数需要在调用函数 `_steqr` 之前被调用，以便计算  $A$  的特征向量。函数 `_ormtr` 用来在不显式计算出  $Q$  的前提下，计算  $Q$  左乘另一个矩阵的结果。这个函数可以用来将函数 `_stein` 返回的  $T$  的特征向量重新转变为  $A$  的特征向量。

用来对矩阵  $T$  求解特征值问题的函数包括以下几种：

- `_steqr`: 使用隐式提升的 QR 算法完成计算。它会自动在 QR 与 QL 算法中进行切换，以便更高效地处理 *graded matrices*。采用的性能优化方法是矩阵分块。
- `_sterf`: 使用一种无开平方运算的 QR 算法完成计算。与 `_steqr` 一样会自动在 QR 与 QL 算法中自动切换。采用的性能优化方法是矩阵分块。
- `_stedc`: 使用一种由 Cuppen 提出的分治算法进行计算。相比 `_steqr`，在大矩阵上其运行速度可能快数倍，但是需要更大的内存开销（ $2n^2$  或  $3n^2$ ）。没有采用特殊的优化手段。
- `_stegr`: 使用 *relatively robust representation (RRR)* 算法完成计算。除了在某些特定例子上，该函数的运行速度比其他所有函数都快，并且使用的内存开销也最小。采用的性能优化方法是矩阵分块。
- `_pteqr`: 此函数仅用于计算对称正定的三对角阵的特征值问题。它使用了一种由 Cholesky 分解和双对角 QR 迭代算法组合而成的算法。该函数的计算结果比其他所有函数（除了 `_stegr`）都要准确。没有采用特

殊的优化手段。

- `_stebz`: 此函数使用二分法计算全部或部分特征值。它可以通过降低对结果的精确度要求来获得更快的运行速度。采用的性能优化方法是分块。
- `_stein`: 此函数用来在给定准确的特征值的前提下通过反向迭代计算部分或全部的特征向量。没有采用特殊的优化手段。

### 3 最小二乘法曲线拟合

#### 3.1 算法简介

给定观测数据  $(x_i, y_i), i = 1, 2, \dots, m$ , 欲通过最小二乘法求解其  $N$  次多项式曲线  $f(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$  的拟合参数, 可通过求解以下线性方程组获得:

$$A^T A \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = A^T \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

其中矩阵  $A$  是如下所示的范德蒙矩阵:

$$A = \begin{bmatrix} 1 & x_1 & x_1^2 & x_1^3 & \cdots & x_1^n \\ 1 & x_2 & x_2^2 & x_2^3 & \cdots & x_2^n \\ 1 & x_3 & x_3^2 & x_3^3 & \cdots & x_3^n \\ \vdots & \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & x_m^3 & \cdots & x_m^n \end{bmatrix}$$

#### 3.2 具体实现及工具说明

曲线拟合参数计算程序使用 C/C++ 语言编写, 运行脚本及绘图脚本使用 python 语言编写。C/C++ 编译器使用 Clang/LLVM 12.0, 编译标准使用 C++17, 优化等级指定为 O3。在 python 绘图脚本中, 绘图库使用 matplotlib.pyplot。实验平台采用 Ubuntu 20.04 LTS, 机器配置为 CPU Intel(R) Xeon(R) Platinum 8260 @ 2.40GHz (48 核心 96 线程), 内存大小 512GB。

实验中, 分别使用三种数学库组合作为后端进行最小二乘计算, 他们是:

- CBLAS-v3.11.0 + LAPACK-v3.11.0
- GotoBLAS2-v1.13 + clapack-v3.10.3-8ubuntu7
- ATLAS-v3.10.3-8ubuntu7 + clapack-v3.10.3-8ubuntu7

以下简要说明工具的编译及使用方法。

首先使用以下命令编译曲线拟合参数计算程序:

```
1 mkdir build
2 cd build
3 cmake ..
4 make
```

在执行 `cmake` 指令时需要额外添加编译选项 `-DBUILD_LAPACK_FROM_SRC=ON`, `-DBUILD_GOTO2=ON` 或 `-DBUILD_ATLAS=ON`, 以指定使用的后端数学库。否则会遇到编译报错。完成编译后, 生成的二进制曲线拟合参数计算程序 `main` 会生成在 `bin` 文件夹下。

`main` 程序可以完成随机数据生成以及多项式曲线拟合参数计算的工作, 其接受以下参数:




Figure 1: M=10000, k=100, N=315, CBLAS




Figure 2: M=50000, k=100, N=315, CBLAS

- -M, 指定随机生成的观察数据的个数（必需）
- -k, 指定参数  $k$ （必需）
- -N, 指定需要拟合的曲线的度数（必需）
- -r, 指定原始观察数据的输出文件夹（非必需，默认生成在当前路径下）
- -f, 指定曲线拟合参数的输出文件夹（非必需，默认生成在当前路径下）

可以使用自动运行脚本 `generate.py` 完成曲线拟合参数计算程序的运行以及后续的绘图工作，命令如下：

```
python3 ./generate.py
```

`generate.py` 中已经定义了一系列待测试的  $(M, k, N)$  参数，如有需要可自行修改。绘制得到的图片存储在 `figures` 文件夹下。

### 3.3 测试结果

#### 3.3.1 拟合效果展示及对比

由于测试数据较多（全部测试数据详见表1），因此本小节中仅展示部分具有代表意义的拟合效果曲线图。实验所涉及的全部拟合效果曲线图可在文件夹 `figures` 下找到。

当参数  $k$  取较小值（以  $k=100$  为例），且多项式度数  $N$  在  $\pi k$  附近取值时，在  $x \in [0.8, 1.0]$  区间上以及零




Figure 3:  $M=10000$ ,  $k=100$ ,  $N=1000$ , CBLAS




Figure 4:  $M=10000$ ,  $k=100$ ,  $N=8000$ , CBLAS

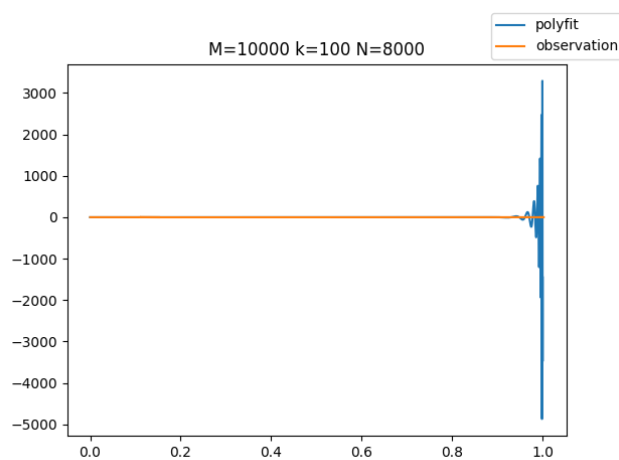
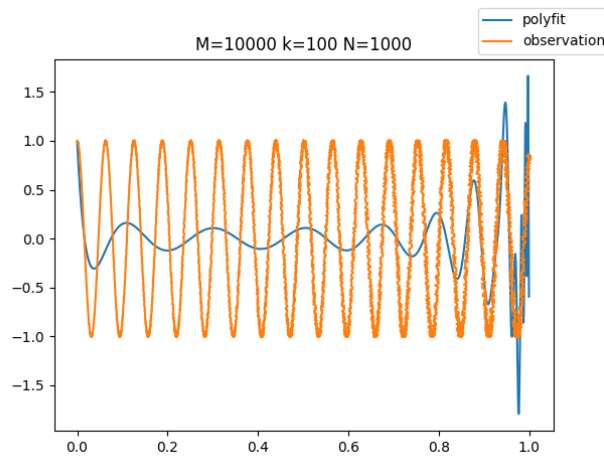



Figure 5:  $M=10000$ ,  $k=100$ ,  $N=8000$ , ATLAS

Figure 6:  $M=10000, k=100, N=1000$ , ATLASFigure 7:  $M=10000, k=150, N=475$ , CBLAS

点附近，拟合所得多项式曲线能够较好地贴合原始曲线，如图1所示，其中橙色曲线为原始观测数据，蓝色曲线为拟合所得的多项式曲线；但是在  $x \in (0, 0.8)$  区间上，由于双精度数据结构精度所限，高次项信息几乎完全丢失，因此拟合效果不够理想，仅能够勉强拟合出原始曲线起伏的变化趋势。增大观测数据的数量  $M$  对曲线拟合几乎没有帮助，如图2所示。增大待拟合多项式的度数  $N$  能够在一定程度上取得更好的效果，拟合曲线在  $x \in (0, 0.8)$  区间上的起伏会变得更从而更贴近原始曲线，但仍然无法捕获原始曲线中存在的高频信息，如图3所示。并且，当  $N$  取值过大时，拟合曲线在靠近 0 点附近（CBLAS）或靠近 1 点（GotoBLAS2 和 ATLAS）附近可能会面临取值爆炸的问题，如图4和5所示。三种数学库组合在处理这些参数时表现差异不大，主要区别在于 CBLAS + LAPACKE 组合拟合得到的曲线较为光滑，而其他两种数学库组合得到的拟合曲线可能出现较多的毛刺，如图6所示。此种差异可能是由于所使用的 lapack 库不同所导致的。由于 GotoBLAS2 和 ATLAS 均与 LAPACKE 存在头文件冲突，因此在实验中使用 ATLAS 自带的 lapack 库 clapack 作为替代。

随着参数  $k$  的增大，由于随机扰动的存在，拟合效果会逐渐变差，只有在非常靠近 1 点的很小范围内拟合曲线能够较好地贴合原始曲线，在其他区间只能非常粗略地捕获到原始曲线的起伏信息，如图7和8所示。在处理这些参数时，使用 LAPACKE 的 CBLAS 的效果明显好于使用 clapack 的 GotoBLAS2 和 ATLAS：当参数  $k$  取一个较大值 500 时，前者拟合得到的曲线在  $x \in (0, 0.8)$  区间上仍呈现出了一定的起伏趋势，如图8所示；而后者在该区间上所得的拟合曲线呈几乎没有起伏的直线，如图9所示。

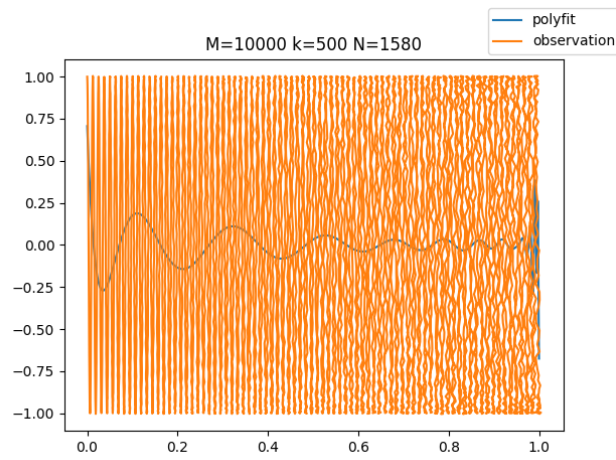


Figure 8:  $M=10000$ ,  $k=500$ ,  $N=1580$ , CBLAS

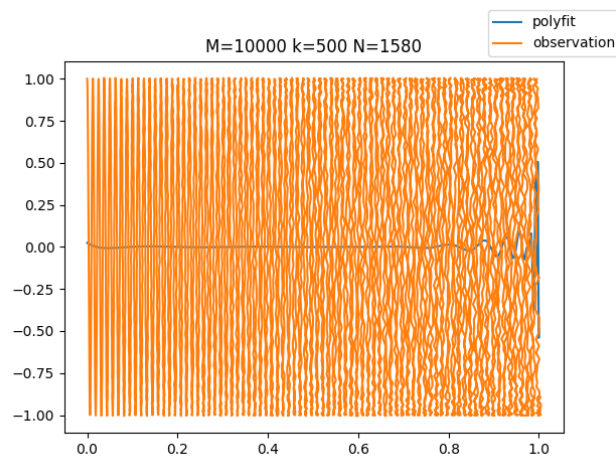


Figure 9:  $M=10000$ ,  $k=500$ ,  $N=1580$ , ATLAS

### 3.3.2 不同数学库拟合效率对比

表1展示了三种数学库在各种参数组合下计算曲线拟合参数所需的时间，其中耗时数据的单位为秒。我同时计算了 GotoBlas2 + clapack 和 ATLAS + clapack 这两种数学库组合相比于 CBLAS + LAPACKE 在时间上取得的加速比，相关结果展示在 *SpeedUp* 列中。由于 GotoBLAS2 库使用多个线程进行矩阵运算，而 CBLAS 和 ATLAS 库均只使用一个线程进行运算，因此，为了使对比更为公平，我在实验中统计 GotoBLAS2 库所有线程耗时的总和作为其耗时的数据。

从表1中可以看出，相比于基础的 CBLAS + LAPACKE 组合，GotoBLAS2 + clapack 组合在计算效率上没有取得优势，并且由于管理多个线程引起的额外开销，其在总体耗时上略高于 CBLAS + LAPACKE 组合（平均计算效率约为 CBLAS + LAPACKE 组合的 0.88 倍）。但是其通过引入并行机制，可以大大提高程序的运行效率。在本次实验中，我观察到 GotoBLAS2 + clapack 组合最多可以使用 32 个线程进行并行运算，因此相比于 CBLAS + LAPACKE 组合，GotoBLAS2 + clapack 组合在运行效率上的加速比能达到约  $0.88 \times 32 = 28.16$ ，从而实现较好的加速效果。ATLAS + clapack 组合则主要通过算法优化来实现运行加速。在与 CBLAS + LAPACKE 组合同样采用单线程模式运行的前提下，ATLAS + clapack 组合相较于 CBLAS + LAPACKE 组合在运行时间上取得的平均加速比为 3.77。因此使用 ATLAS + clapack 组合在无法并行运算的环境下也能够取得不错的加速效果。

Table 1: 三种数学库曲线拟合耗时信息统计

参数组合 (M, k, N)	CBLAS + LAPACKE	GotoBLAS2 + clapack	SpeedUp	ATLAS + clapack	SpeedUp
(10000, 100, 315)	1.57	2.16	0.73x	0.43	3.65x
(50000, 100, 315)	8.30	8.62	0.92x	1.99	4.17x
(10000, 100, 400)	2.70	3.64	0.74x	0.73	3.70x
(10000, 100, 500)	4.54	5.70	0.80x	1.26	3.60x
(10000, 100, 1000)	19.63	20.06	0.98x	5.53	3.55x
(10000, 100, 2000)	81.14	88.66	0.92x	22.22	3.65x
(10000, 100, 5000)	535.61	649.73	0.82x	139.57	3.84x
(10000, 100, 8000)	1412.61	1622.28	0.87x	344.35	4.10x
(10000, 120, 380)	2.39	3.21	0.74x	0.65	3.68x
(50000, 120, 380)	12.67	13.15	0.96x	3.19	3.97x
(10000, 120, 500)	4.49	5.75	0.78x	1.24	3.62x
(10000, 120, 800)	12.47	13.96	0.89x	3.43	3.64x
(10000, 120, 1000)	19.53	20.33	0.96x	5.34	3.66x
(10000, 120, 2000)	80.70	89.69	0.90x	22.11	3.65x
(10000, 120, 5000)	539.62	650.14	0.83x	140.34	3.85x
(10000, 120, 8000)	1419.56	1624.80	0.87x	341.58	4.16x
(10000, 150, 475)	3.99	5.18	0.77x	1.10	3.63x
(50000, 150, 475)	20.83	20.71	1.00x	5.36	3.89x
(10000, 150, 500)	4.48	5.76	0.78x	1.24	3.61x
(10000, 150, 800)	12.47	13.98	0.89x	3.42	3.65x
(10000, 150, 1000)	19.53	20.31	0.96x	5.35	3.65x
(10000, 150, 2000)	80.71	88.88	0.91x	22.12	3.65x
(10000, 150, 5000)	539.83	649.92	0.83x	138.86	3.89x
(10000, 150, 8000)	1435.05	1625.58	0.88x	339.63	4.23x
(10000, 200, 630)	7.51	9.09	0.83x	2.07	3.63x
(50000, 200, 630)	38.11	36.55	1.04x	10.17	3.75x
(10000, 200, 800)	12.44	13.95	0.89x	3.41	3.65x
(10000, 200, 1000)	19.47	20.14	0.97x	5.36	3.63x
(10000, 200, 2000)	80.44	88.80	0.91x	22.14	3.63x
(10000, 200, 5000)	538.72	651.66	0.83x	139.83	3.85x
(10000, 200, 8000)	1428.07	1625.10	0.88x	338.92	4.21x
(10000, 500, 1580)	49.48	50.61	0.98x	13.48	3.67x
(50000, 500, 1580)	243.95	235.18	1.04x	66.93	3.67x
(10000, 500, 3000)	187.54	226.16	0.83x	50.89	3.68x
(10000, 500, 5000)	537.23	649.43	0.83x	139.94	3.84x
(10000, 500, 8000)	1425.89	1624.83	0.88x	342.92	4.16x
(50000, 500, 3000)	874.40	1090.35	0.80x	244.21	3.58x
平均值	-	-	0.88x	-	3.77x